

Inteligencia Artificial

Actividad 4 - Métodos de aprendizaje no supervisado

Descripción de los datos

Francisco Luis Ramírez Galvis

Juliana Campos Florez

Juan Esteban Fierro Cortes

Sandra Isabel Rodríguez Bautista

Docente

Corporación Universitaria Iberoamericana

Facultad de Ingeniería

Ingeniería de Software

Octubre, 2026

1. Introducción

Este documento describe la fuente de datos utilizada en la Actividad 4 para el desarrollo de un modelo de aprendizaje no supervisado sobre el sistema de transporte masivo MIO de Cali. A diferencia de la actividad anterior, en la que el modelo aprendía a predecir una etiqueta conocida, aquí los datos no tienen etiqueta: el objetivo es que técnicas de agrupamiento como K-Means descubran por sí solas grupos de usuarios con un comportamiento de viaje similar. Identificar estos perfiles es útil para planear la oferta del servicio, diseñar tarifas o campañas dirigidas y anticipar la demanda.

2. Identificación de fuentes de datos

La fuente natural para este análisis son los registros de uso de la tarjeta MIO, que gestiona Metrocali S.A.: cada validación en una estación indica cuándo y dónde viaja un usuario. Sin embargo, estas transacciones están asociadas a personas y constituyen datos personales protegidos por la Ley 1581 de 2012 de protección de datos en Colombia, por lo que no se publican de forma abierta. En el portal de datos abiertos del Estado (datos.gov.co) se encuentra información general del sistema, pero no el comportamiento individual de los usuarios.

Por esta razón, y tal como lo contempla la actividad, se desarrolló un dataset de muestra que representa de forma realista el comportamiento de distintos tipos de usuarios del MIO, sin corresponder a ninguna persona real.

3. Construcción del dataset

El dataset se genera con el script generar_dataset.py, con una semilla aleatoria fija (42) que lo hace reproducible. Contiene 600 usuarios; cada uno se describe con seis variables numéricas que resumen su comportamiento durante un mes típico.

Para que los datos tengan una estructura realista, cada usuario se genera a partir de uno de cuatro perfiles de comportamiento. Para cada perfil se definió un valor promedio y una variación de cada variable, de modo que los usuarios de un mismo perfil se parecen entre sí, pero no son idénticos, y algunos quedan en la frontera entre perfiles, como ocurre en la realidad.

Perfil	Usuarios	Viajes por semana	Hora primer viaje	% fin de semana	Transb. por viaje	Km por viaje	Recargas al mes
Trabajador de rutina	221	11	6:30	5	1,0	9	4
Estudiante	142	9	9:30	10	0,6	5	7
Ocasional de fin de semana	164	3	11:00	65	0,4	6	1,5
Largo recorrido	73	10	5:30	12	2,2	17	5

Tabla 1. Perfiles de comportamiento y valores promedio de cada variable.

Es importante señalar que el perfil con el que se generó cada usuario no forma parte de los datos del modelo. Se guarda en un archivo aparte, perfiles_referencia.csv, y solo se utiliza en la etapa de pruebas para verificar si los grupos que descubre el algoritmo coinciden con los perfiles reales. Esta es una ventaja de trabajar con datos de muestra: en un caso real no se conocería la respuesta correcta.

4. Diccionario de datos

Variable	Tipo	Rango	Descripción
id_usuario	Identificador	U0001 a U0600	Código anónimo del usuario. No se usa en el agrupamiento.
viajes_semana	Numérica entera	1 a 20	Número promedio de viajes que realiza el usuario por semana.
hora_primer_viaje	Numérica decimal	4,5 a 21,0	Hora habitual del primer viaje del día, en formato decimal (6,5 = 6:30 a. m.).
pct_viajes_fin_semana	Numérica decimal	0 a 100	Porcentaje de los viajes del usuario que ocurren en sábado o domingo.
transbordos_promedio	Numérica decimal	0 a 4	Número promedio de transbordos (cambios de bus) por viaje.
distancia_promedio_km	Numérica decimal	1 a 30	Distancia promedio recorrida por viaje, en kilómetros.
recargas_mes	Numérica entera	1 a 15	Número de recargas de la tarjeta que hace el usuario en el mes.

Tabla 2. Diccionario de datos del archivo usuarios_mio.csv.

El archivo perfiles_referencia.csv contiene dos columnas: id_usuario, que permite relacionarlo con el archivo principal, y perfil_real, con el perfil con el que se generó el usuario.

5. Estadísticas descriptivas

Variable	Media	Desv. estándar	Mínimo	Mediana	Máximo
viajes_semana	8,26	3,53	1,00	9,00	15,00
hora_primer_viaje	8,31	2,46	4,79	7,54	15,58

Variable	Media	Desv. estándar	Mínimo	Mediana	Máximo
pct_viajes_fin_semana	23,27	26,09	0,00	10,45	90,00
transbordos_promedio	0,91	0,65	0,00	0,78	3,22
distancia_promedio_km	8,33	4,36	1,00	7,10	22,40
recargas_mes	4,13	2,20	1,00	4,00	11,00

Tabla 3. Estadísticas descriptivas de las variables.

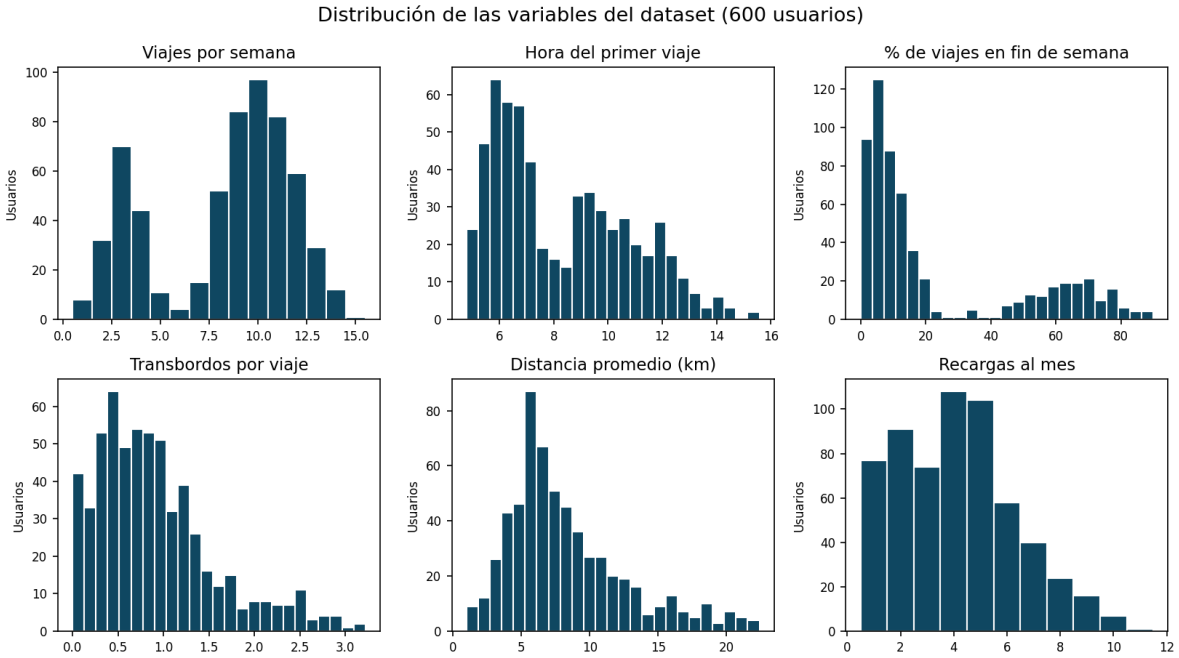


Figura 1. Distribución de las variables del dataset.

Las distribuciones ya sugieren la existencia de grupos. Por ejemplo, los viajes por semana muestran dos concentraciones, una alrededor de 3 viajes y otra entre 9 y 12; y el porcentaje de viajes en fin de semana separa claramente a un grupo con valores cercanos a 0 % de otro con valores entre 40 % y 85 %. Estas agrupaciones naturales son las que el algoritmo de agrupamiento debe descubrir.

6. Relación entre variables

El análisis de correlación muestra relaciones coherentes con el comportamiento esperado: los usuarios que viajan más por semana viajan menos en fin de semana (correlación de −0,87) y empiezan su día más temprano (−0,72); y los usuarios que recorren mayores distancias hacen más transbordos (0,69). Estas relaciones confirman que el dataset tiene una estructura con sentido y no es aleatorio.

7. Calidad y preparación de los datos

1. El dataset no presenta valores nulos ni identificadores repetidos: los 600 usuarios tienen sus seis variables completas.

2. Todas las variables de entrada son numéricas, el tipo de dato adecuado para algoritmos basados en distancias como K-Means.

3. Las variables están en escalas muy distintas (por ejemplo, el porcentaje de fin de semana va de 0 a 100, mientras que los transbordos van de 0 a 4). Como K-Means agrupa según la distancia entre usuarios, las variables con valores más grandes dominarían el cálculo. Por eso, antes de agrupar, las variables se estandarizan para que todas tengan media 0 y desviación estándar 1 y pesen por igual.

4. Los valores de cada variable se recortaron a rangos válidos durante la generación, por lo que no existen datos imposibles, como viajes negativos u horas fuera del horario de operación.

8. Archivos de la fuente de datos

1. datos/usuarios_mio.csv: datos de entrada del modelo, con 600 usuarios y sus seis variables de comportamiento, en formato CSV separado por comas y codificación UTF-8.

2. datos/perfiles_referencia.csv: perfil real de cada usuario, utilizado únicamente en las pruebas.

3. generar_dataset.py: script en Python que construye ambos archivos y permite regenerarlos con el comando python3 generar_dataset.py.

Referencias

Congreso de la República de Colombia. (2012). Ley 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales.

Metrocali S.A. (s.f.). Sistema de Transporte Masivo MIO. https://www.metrocali.gov.co/

Gobierno de Colombia. (s.f.). Portal de datos abiertos. https://www.datos.gov.co/

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España.

Pedregosa, F., Varoquaux, G., Gramfort, A., y otros. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.